

# CycleGAN 기반 데이터 생성을 통한 결함데이터 분류에서의 Class Imbalance 해소

강동기, 최장훈\*  
경북대학교 데이터사이언스 대학원

## Resolving class imbalance in Defect Data Classification with CycleGAN-based Data Generation

Donggi Kang, Janghoon Choi\*  
Graduate School of Data Science  
Kyungpook National University  
E-mail: kangdg22@gmail.com, jhchoi09@knu.ac.kr\*

### Abstract

Recently, in various industries where image data is available, deep learning models are used to classify normal and defective data. In this process, a large amount of training data is required, and the generalization performance of the classification model may decrease due to the imbalance of each class of data. In this paper, we address the class imbalance problem by adding images obtained by converting normal data to defective data using the CycleGAN model to classes with less data. Subsequently, to verify whether the proposed method can improve the accuracy of the classification model. We conducted experiments using two types of datasets and added images generated by CycleGAN to five and three classes, respectively. The experimental results show that the proposed method can improve the classification performance in various models than the existing method.

### I. 서론

최근 인공지능 분야의 발전으로 제조업을 비롯한 의료, 스마트팜 등 다양한 산업에서 딥러닝을 사용하는 사례가 늘고 있다. 여러 도메인에서 얻어지는 이미지 데이터의 특성추출을 목적으로 Convolutional neural

network(CNN)[4] 모델이 주로 사용되는데, CNN 을 비롯한 딥러닝 모델을 학습시키기 위해서는 충분한 양의 데이터 확보가 필수적이다. 하지만 충분한 데이터 확보에는 많은 시간과 비용이 소요되며 특히 비정상 데이터의 경우 정상적인 데이터에 비해 간헐적으로 생산되기 때문에 확보에 어려움이 있다. 위와 같이 어떤 도메인에서 데이터가 부족할 경우 일반적으로 이미지 회전, 확대, 자르기, 색상변환과 같은 고전적인 Data augmentation 기법을 사용하여 모델의 성능을 개선하고 과적합을 방지할 수 있다 [7]. 그러나 Augmentation 역시도 과도하게 적용할 경우 Training data 에 과적합 될 우려가 있다. 따라서 적대적 생성 신경망(GAN) [1]을 통해 Data augmentation 에 활용하는 연구들이 진행되고 있다. 이 논문에서는 2 개의 Generator 와 Discriminator 를 통해 unpaired 데이터에서도 image translation 이 가능한 CycleGAN[11] 모델을 사용하였다. 이를 통해 이미지를 다른 스타일로 변환하는 Image-to-Image translation [6] 기법을 적용하여 정상 이미지를 비정상 이미지로 변환하였다. 이후 분류모델에서 Training-dataset 에 생성된 이미지를 추가하기 전, 후의 성능을 비교하여 해당 방법이 모델의 성능 향상에 긍정적인 영향이 있음을 입증한다.

## II. 관련연구

CycleGAN 은 도메인  $X, Y$  에서 각각 2 개의 Generator 와 Discriminator ( $G, F$ )와 ( $D_x, D_y$ )를 통해 이미지를 생성 하게 된다. Generator  $G$  를 통해  $X$ 에서  $Y$  도메인으로 변환시켜  $D_y$ 가 판별하기 어렵게 학습되고 Generator  $F$  는  $Y$ 를  $X$ 로 변환시켜  $D_x$  가 판별하기 어렵게 학습된다.  $X$  도메인에서  $Y$  로 변환할 때의 Adversarial loss 는 아래와 같으며  $Y$  도메인에서  $X$  로 변환될때는  $\mathcal{L}_{GAN}(F, D_x, Y, X)$  가 사용된다.

$$\mathcal{L}_{GAN}(G, D_y, X, Y) = \mathbb{E}_{y \sim p_{data}(y)} [\log D_y(y)] + \mathbb{E}_{x \sim p_{data}(x)} [\log(1 - D_y(G(x)))] \quad (1)$$

추가로 Cycle consistency loss 를 사용하게 되는데 이는  $X$  에서  $Y$  로 변환된 이미지를 다시  $X$  도메인으로 되돌리는데 이때 원본 이미지와 변환된 이미지의 차이를 최소화하도록 학습된다. 이를 통해 Unpair 한 데이터셋에서도 원본 이미지의 형태를 유지하며 다른 도메인으로 변환이 가능하게 한다. Cycle consistency loss 의 식은 아래와 같다.

$$\mathcal{L}_{cyc}(G, F) = \mathbb{E}_{x \sim p_{data}(x)} [\|F(G(x)) - x\|_1] + \mathbb{E}_{y \sim p_{data}(y)} [\|G(F(y)) - y\|_1] \quad (2)$$




그림 1. CycleGAN 구조

## III. 실험

이 논문에서는 CycleGAN 을 통한 Image-to-image Translation 을 수행하기 위해 과수작물 통합 데이터 [10] 와 Concrete Defect Image [11]를 채택하였다. 각 데이터의 클래스는 다음과 같다.

	귤	키위
정상		
비정상		

그림 2. 과수작물 데이터

정상		
Decks Non-Cracked	Pavements Non-Cracked	Walls Non-Cracked
비정상		
Decks Cracked	Pavements Cracked	Walls Cracked

그림 3. Concrete Defect Image 데이터

위 데이터를 이용해 CycleGAN 이 정상 데이터를 비정상 데이터로 변환할 수 있게 학습시켰다. 과수작물 데이터의 비정상에 해당하는 (귤)궤양병, (귤)진딧물, (귤)굴응애, (키위)충채벌레, (키위)점무늬병에 대한 이미지를 생성할 때 CycleGAN 모델의 혼동을 줄이기 위해 객체 부분을 제외한 배경의 RGB 값을 255 로 변경하였고 Generator 가 한 번 업데이트 될 때 Discriminator 는 3 번 업데이트 되도록 조절하여 Mode Collapse 를 방지하였다.

Concrete defect Image 데이터에서 Decks Cracked, Pavements Cracked, Walls Cracked 를 생성할 때는 Discriminator 를 2 번 업데이트 하는것으로 설정하였다. 학습시 Learning rate 는 0.0003, Epoch 는 2000 으로 설정하였고 optimizer 는 Adam[3]을 사용하였다. Train data 는 모든 클래스에서 100 장의 이미지를 사용하였다. 생성 결과는 다음과 같다.

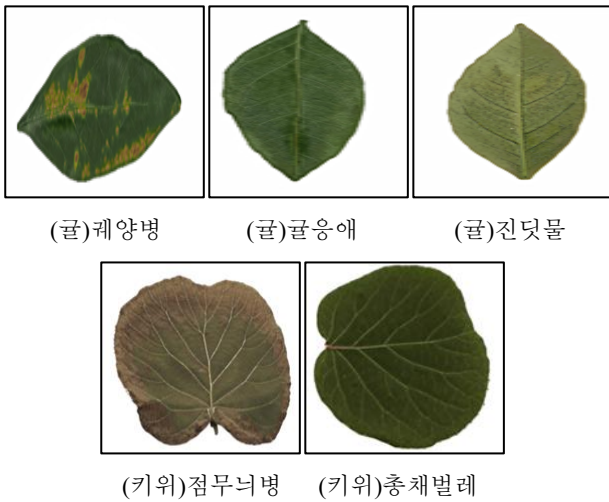


그림 4. 과수작물 CycleGAN 생성 데이터




그림 5. Concrete Defect Image CycleGAN 생성 데이터

생성 이미지를 확인한 결과 원본이미지의 특성이 반영된 이미지가 생성된 것을 확인할 수 있었다.

## IV. 실험 결과

CycleGAN 을 통해 생성된 이미지의 Data Augmentation 으로서 효과를 검증하기 위해 분류모델에서 Class Imbalance 한 상황을 가정하여 성능을 측정한 후 CycleGAN 을 통해 생성한 이미지를 추가하여 다시 성능을 측정하였다. 사용된 데이터 수는 다음과 같다.

	기본 데이터 수	CycleGAN 추가 데이터 수
(귤)정상	1200	X
(키위)정상	1200	X
(귤)궤양병	300	100
(귤)굴응애	300	100
(키위)점무늬병	300	100
(키위)충채벌레	300	100

표 1. 과수작물 데이터 Training set

	기본 데이터 수	CycleGAN 추가 데이터 수
Decks Non Cracked	800	X
Pavements Non Cracked	800	X
Walls Non Cracked	800	X
Decks Cracked	150	30
Pavements Cracked	150	30
Walls Cracked	150	30

표 2. Concrete Defect Image 데이터 Training set

위와 같이 정상 데이터와 비정상데이터의 비율을 설정하였고 해당 조건에서 분류모델의 Accuracy, F1 score 를 측정한 후 CycleGAN 을 통해 생성된 데이터를 추가하여 모델 성능을 비교하였다. Batchsize=4, LearningRate=0.001 로 고정하였고 optimizer 는 AdamW[5]를 사용했다. 실험은 Resnet34, Resnet50 [2], Efficientnet-b3, Efficientnet-b7 [8] 위 네가지모델로 진행하였다. Test Set 은 모든 클래스에서 200 장의 이미지를 사용하였다. 실험 결과는 다음과 같다.

	과수작물 데이터	
	Baseline	CycleGAN 이미지 추가
Resnet34 (Epoch=60)	Acc: 72.21 F1: 71.08	74.14(+1.93) 74.14(+3.06)
Resnet50 (Epoch=60)	73.14 72.32	76.57(+3.42) 76.42(+4.10)
Efficientnet b3 (Epoch=80)	84.43 83.90	88.14(+3.70) 88.06(+4.15)
Efficientnet b7 (Epoch=80)	84.79 84.31	90.21(+5.42) 90.09(+5.78)

표 3. 과수작물 데이터 분류모델별 성능

	Concrete defect image	
	Baseline	CycleGAN 이미지 추가
Resnet34 (Epoch=60)	Acc: 71.77 F1: 70.36	74.69(+2.92) 73.60(+3.24)
Resnet50 (Epoch=60)	70.41 67.97	73.77(+3.36) 73.06(+5.09)
Efficientnet b3 (Epoch=80)	74.52 72.65	76.69(+2.17) 76.33(+3.68)
Efficientnet b7 (Epoch=80)	75.35 74.72	76.69(+1.34) 76.03(+1.31)

표 4. Concrete defect image 데이터 분류모델별 성능

각 모델별 표기된 Epoch 만큼 학습하였고 학습 중 Validation set 에 대하여 가장 높은 Accuracy 를 기록한 모델의 파라미터를 저장하여 Test set 에 사용하였다. 실험 결과 CycleGAN 을 통해 생성된 이미지를 추가한 것이 Class Imbalance 문제를 완화할 수 있으며 모델의 Accuracy, F1 score 에 긍정적인 영향을 줄 수 있음을 확인하였다.

## V. 결론

본 논문에서는 CycleGAN 을 통하여 Class imbalance 를 완화하고 모델의 성능을 향상시킬 수 있음을 확인하였다. 이 과정에서 2 개 데이터셋을 사용하여 서로 다른 도메인에서 해당 방법이 유효함을 확인하였으며 향후 메디컬, 스마트팜, 제조업 등 다양한 도메인의 정상 데이터와 이상 데이터를 구분하는 것에 도움이 될 것으로 생각하며 더 나아가 이상탐지 분야에서 해당 방법을 활용할 수 있을 것으로 기대한다.

## 참고문헌

[1] Goodfellow, Ian, et al. "Generative adversarial

nets." *Advances in neural information processing systems* 27, 2014.

[2] He, Kaiming, et al. "Deep residual learning for image recognition." *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016.

[3] Kingma, Diederik P., and Jimmy Ba. "Adam: A method for stochastic optimization." *arXiv preprint arXiv:1412.6980*, 2014.

[4] LeCun, Yann, et al. "Gradient-based learning applied to document recognition." *Proceedings of the IEEE* 86.11, 1998.

[5] Loshchilov, Ilya, and Frank Hutter. "Decoupled weight decay regularization." *arXiv preprint arXiv:1711.05101*, 2017.

[6] Pang, Yingxue, et al. "Image-to-image translation: Methods and applications." *IEEE Transactions on Multimedia* 24, 2021.

[7] Shorten, Connor, and Taghi M. Khoshgoftaar. "A survey on image data augmentation for deep learning." *Journal of big data* 6.1, 2019.

[8] Tan, Mingxing, and Quoc Le. "Efficientnet: Rethinking model scaling for convolutional neural networks." *International conference on machine learning*. PMLR, 2019.

[9] Zhu, Jun-Yan, et al. "Unpaired image-to-image translation using cycle-consistent adversarial networks." *Proceedings of the IEEE international conference on computer vision*, 2019.

[10] <https://aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=realm&dataSetSn=635>

[11] <https://www.kaggle.com/datasets/datastrophy/concrete-train-test-split-dataset>